1、Spark概述

- Spark是使用Scala语言开发的，用于大型分布式数据处理和分析的计算引擎。它本身不是数据库，但是可以通过其Spark和Hadoop生态系统里面的其他组建连接其他关系数据库（比如MySql), 非关系数据库NoSql(redis, Hadoop HDFS), 流处理和信息队列(Kafka).
- Spark的计算基于内存而不是硬盘，使用**速度非常快**。Spark引擎内部使用有向无环图(DAG)来优化查询和计算语句，自动建立可以分布式计算的'计算图'。其核心是弹性数据集(Resilient distributed datasets RDD)可在内存中迭代计算，更加适合运行需要交换数据的应用比如训练大型机器学习算法。
- Spark的结构和功能组件：

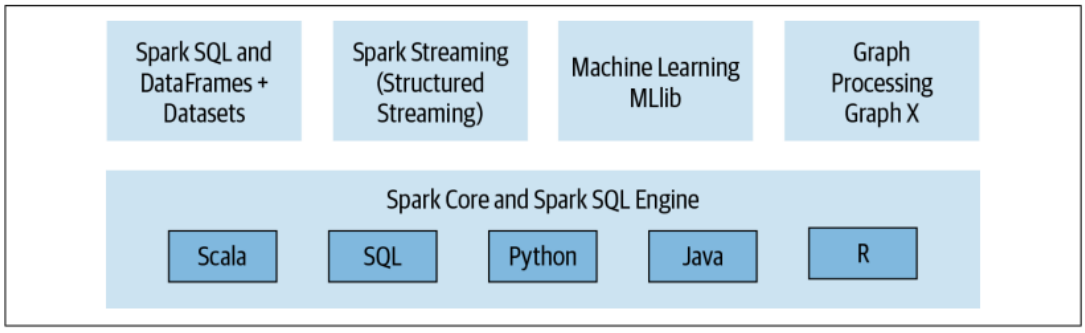

- **Spark core:** 提供核心的功能，用户使用不同语言的API然后交由Spark core优化运行，根据其支持的语言比如Scala Pyton Java等都会被优化转译为字节码，运行在集群机器中的JVM中。**Spark SQL**: 使用类似于SQL 语言的方式查询数据。**Spark Streaming**: 用于实时数据的流计算。**Spark MLLib** 集成了机器学习算法。**Spark GraphX** 实现图计算相关算法。
- Spark 语句是怎么样被"分布式"执行的：如下图每一个Spark应用有这些组成部分，driver,负责控制cluster的运行；driver 通过spark Session作为开发的接口来控制cluster manager.和spark exscutrer.

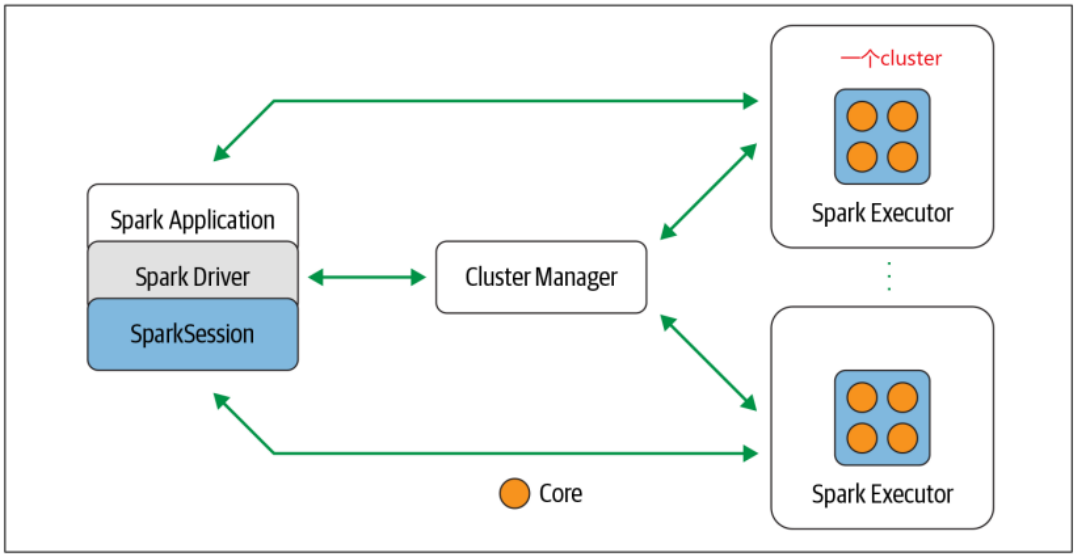

- **Spark driver:** 主要任务 与cluster manager通信并申请计算资源(CPU 内存)给spark executor(本质上是JVM)使用; 将所有操作转化成DAG形式，并分配到集群中的各个executor上执行计算。
- **Spark Session:** spark2.0后，同一的编程接口，所有操作都通过这个session进行。通过这个接口可以定义数据集并使用导入数据的函数、调整JVM参数，执行SQL语句等等。

```
```
// In Scala
import org.apache.spark.sql.SparkSession
```
```

```
// Build SparkSession
val spark = SparkSession
 .builder
 .appName("LearnSpark")
 .config("spark.sql.shuffle.partitions", 6)
 .getOrCreate()
...
// Use the session to read JSON
val people = spark.read.json("...")
...
// Use the session to issue a SQL query
val resultsDF = spark.sql("SELECT city, pop, state, zip FROM table_name")
```

- **Cluster manager**: 负责管理集群中spark 运行中的node的资源。当前支持的有Spark 内置、Hadoop YARN, Apache Mesos, Kubernetes.
- **Spark executor**: 集群中的算节点，负责执行driver分配的任务，一般一个节点就只有一个executor. 实现来说是一个JVM(java虚拟机)。可以是同一个主机，但是是虚拟机里面的不同实体创建的jvm, 也可以是一个很大的机房里物理意义上不同的机器，通过drive程序通信和执行计算过程。
- **Spark Docker 安装教程**

2、Spark 的核心，RDD，DataFrames 和DataSets

- 一点背景：这三种作用都是类似的，是Spark提供的数据处理的接口，所有操作都基于这之上在提供的API里进行。Spark 1.0时代是RDD, 后来1.3有了DataFrame, 1.6之后有了DataSet. 之后在2016年为了简化Spark团队又将后两者融合在一起了。它们有自己的特点和优势，不是说有了最新的DataSet了RDD就可以完全不用了。
- **RDD优势**：1、高效和速度。2、一致性，RDD不可更改保证了数据可靠性。3、容错性，数据分别存在节点上，可重新计算会找回丢失的数据。
- **RDD 什么时候用**：1、数据为非结构化数据，文本图像等等。2、数据没有严格的像数据库的模式定义，不想表格数据一样每一行有严格定义。
- 在JVM实现中，DataFrame 只是DataSet 的行（row). 由于Python是动态语言，只能使用DataFrame.
- **DataSet/DataFrame 优势**： 使用简单，代码较少，用编译和运行速度换开发速度。有专门的优化器优化底层代码，高效。**适用情况**：非结构化数据，需要对数据进行较高层次处理 比如SQL语句。

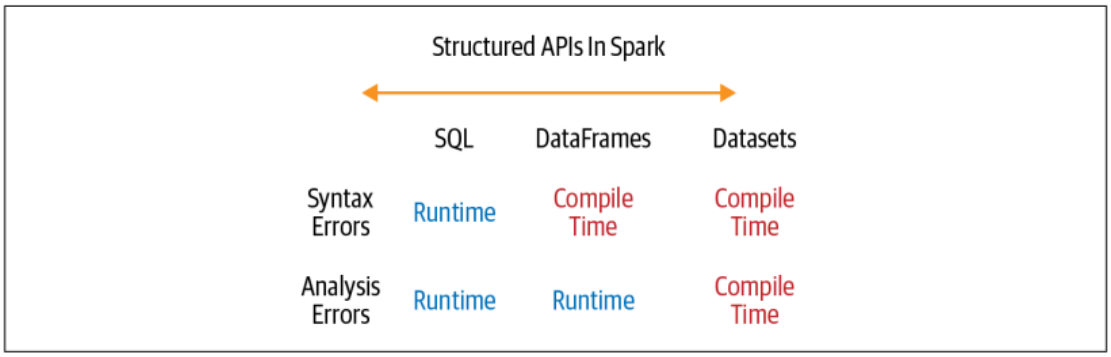

2.1 RDD和DataSet的创建

- Spark API入口：SparkSession(新，2.0版本后) 和Spark Context(旧的方式，1.0版本)

```
import org.apache.spark.sql.SparkSession
val spark:SparkSession = SparkSession.builder()
      .master("local[1]")
      .appName("SparkByExamples.com")
      .getOrCreate()
```

- 来自内存的一个对象集合，来自外部数据集输入，对已有RDD的转换。

```
// entrance of Spark is spark context
// spark context available as sc

// 定义1到10， 并并行化计算，并行度由运行代码的内核数确定
val params = sc.parallelize(1 to 10)
val result = params.map(performExpensiveComputation)

// outside data source
// define String type RDD
val text: RDD[String] = sc.textFile(path)
```

- DataFrame 可以想象成就是一个数据库的表，或者python pandas里面的dataFrame一样，由严格定义的行和列。DF有多种方式建立，读取外部的结构化数据表，Hive，现有的RDD.
- 建立DF:
- ```
  // create DataFrame
  val data = Seq(('James','','Smith','1991-04-01','M',3000),
    ('Michael','Rose','','2000-05-19','M',4000),
    ('Robert','','Williams','1978-09-05','M',4000),
    ('Maria','Anne','Jones','1967-12-01','F',4000),
    ('Jen','Mary','Brown','1980-02-17','F',-1)
  )

  val columns =
  Seq("firstname","middlename","lastname","dob","gender","salary")
  df = spark.createDataFrame(data), schema = columns).toDF(columns:_*)

  df.show()
  >output:
  +---------+----------+--------+----------+------+------+
  |firstname|middlename|lastname|dob       |gender|salary|
  +---------+----------+--------+----------+------+------+
  |James    |          |Smith   |1991-04-01|M     |3000  |
  |Michael  |Rose      |        |2000-05-19|M     |4000  |
  |Robert   |          |Williams|1978-09-05|M     |4000  |
  |Maria    |Anne      |Jones   |1967-12-01|F     |4000  |
  |Jen      |Mary      |Brown   |1980-02-17|F     |-1    |
  +---------+----------+--------+----------+------+------+
  ```
  ```

2.2 RDD的转换和动作

- RDD提供了两种操作，**转换transformation**, 即从现有RDD生成新的RDD. **动作action**. 则是对其进行某种计算 执行某种操作，结果要么返回给用户或者储存到外部。转换使用lazy evaluation, 对RDD执行一个动作前对不会对转换操作执行实际动作。判断是T还是A, 如果一个操作的返回类型是RDD, 那它是一个转换操作，否则是动作。
- 常见的转换：flatMap(), map(), reduceByKey(), filter(), sortByKey()
- 常见的动作：count(), collect(), first(), max(), reduce()

2.3 持久化

- 将计算的结果数据集缓存的到内存中，便于下一步计算时调用。对于大型应用，交互频繁的迭代算法这样可以大大节约时间。Hadoop 的MapReduce在执行另一个计算时必须要从硬盘中重新加载，即使这个数据是作为中间数据输入的，而Spark持久化可以在集群的内存中储存，要知道内存和硬盘的提取速度快了不止一个数量级了。
- 持久化的级别：cache()会将executor的内存持久化保存在每个分区，如果大小不够计算不会失败只是会重新计算分区大小，但是如果计算量大这样的代价还是很大，因此提供了一些折中的方法：序列化数据，再将数据储存。默认为MEMORY_ONLY, 序列化后的参数MEMORY_ONLY_SER. 虽然序列化需要一些计算时间，但是它生成更小更易储存的字节而不是对象。

```
// 假设现有 年份 当年某地温度的tuple数据
// (year, tempureture)
tuples.cache()
// cache()不会立即缓存RDD，直到下一个job运行时被缓存
// 取最大值
tuples.reduceByKey((a,b) => Math.max(a,b)).foreach(println(_))
> ...INFO: Added rdd ...

//运行另一个job，该RDD被加载
tuples.reduceByKey((a,b) => Math.min(a,b)).foreach(println(_))
```

2.4 序列化

- Spark 通过网络在executor之间传递数据和持久化数据前都要经过序列化，即将要对象或类转成字节。可以用Java内置的java.io.Serializable, 但是效率较低。一般使用更加高效的Kryo 序列化库。
- 使用Kyro ，先在设置中定义序列化的属性，然后需要先注册你定义的类。
- 序列化函数（也称为**闭包函数**）：函数也是需要被序列化的，如果引入了不可被序列化的类方法，需要在开发的时候发现它。

```
// 设置属性
conf.set("spark.serializer", "org.apache.spark.serializer.KryoSerializer")

// 注册,重写registerClasses() 的方法
class CustomKryoRegistrator extends KryoRegistrator{
    override def registerClasses(kryo: Kryo){
        kryo.resgitere(classOf[YOUR_CLASS_NAME])
    }
}

// 在driver程序中设置
conf.set("spark.kryo.registrator", "CustomKryoRegistrator")
```

2.5 共享变量

- 查询经常会使用到外部变量，这个变量一般在另一个节点或者集权上，所以如上文外部函数需要通过序列化后传输，这样有时候会降低效率。广播变量(broadcast variable)提供了一种解决方法。

```
//一个程序用到另一个查找表
val lookup = Map(1 -> "a", 2 -> "e", 3 -> "i", 4 -> "o", 5 -> "u")
val result = sc.parallelize(Array(2, 1, 3)).map(lookup(_))
assert(result.collect().toSet === Set("a", "e", "i"))
```

- **广播变量**：序列化后放送给各个executor并缓存以便适时调用，常规变量因为时在函数内部的，所以每次任务都需要序列化传输。现有创建一个sc.broadcast变量，返回对应类型的封装。广播变量是单向传播的，无法更新，也无法从executor传会driver.

```
val lookup: Broadcast[Map[Int, String]] =
   sc.broadcast(Map(1 -> "a", 2 -> "e", 3 -> "i", 4 -> "o", 5 -> "u"))
val result = sc.parallelize(Array(2, 1, 3)).map(lookup.value(_))
assert(result.collect().toSet === Set("a", "e", "i"))
```

3、Spark内部运行机制

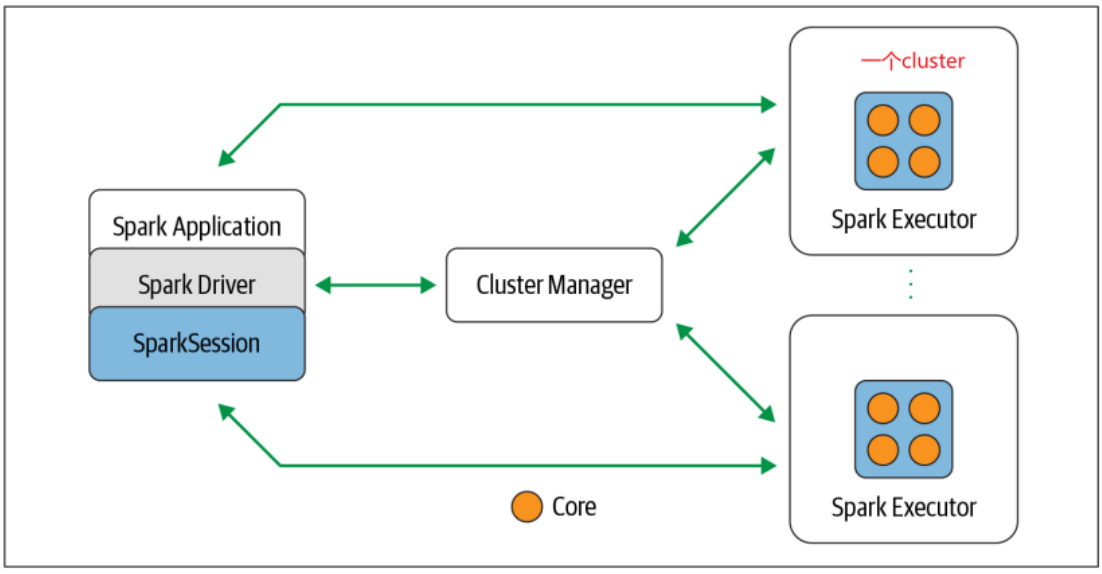

- 回顾上文图2，Spark运行时有两个独立实体，driver 和executor. Driver负责管理调度SparkContext应用，executor专属于应用，应用运行它就运行并执行该应用的任务。

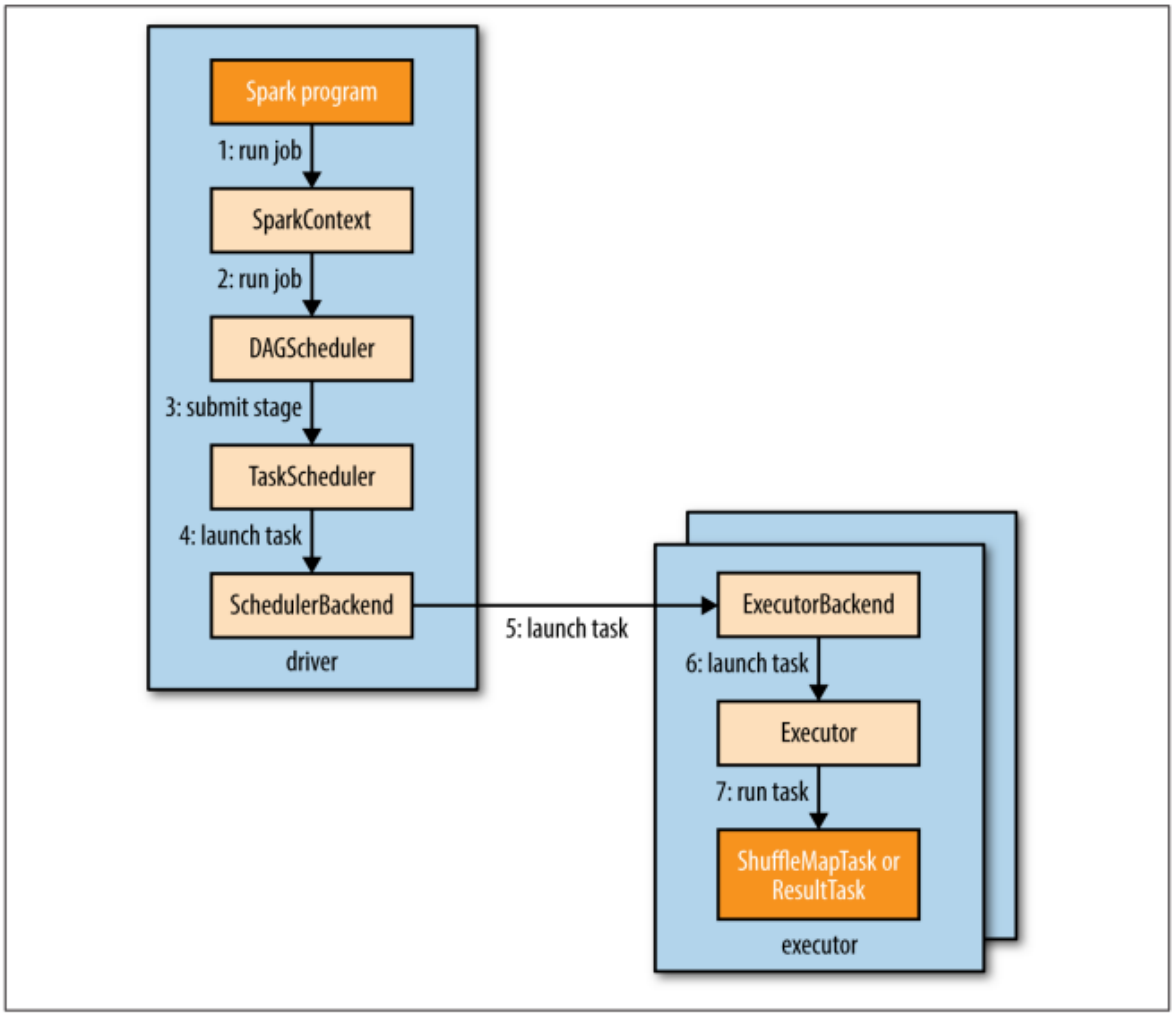

- **作业提交**: 上图,当用户提供SparkContex调用一个动作(action)时，spark自动提交一个jb(步骤2)，然后运行两个调度程序，**DAG调度**和**任务调度**。DAG调度负责将任务分解为若干阶段并将这些阶段构成一个DAG,任务调度这负责把这些分解的每个阶段提交到不同的集群执行。
- **DAG构建**： 一个job怎样被分为不同阶段。job阶段有两种类型的任务，shuffle map 和 result, shuffle map类似于你需要分开10kg混合在一起的红绿豆，现在将它分成10份分给你的10个倒霉朋友每个朋友作为一个cluster执行1kg的分开两种颜色的任务。result任务则是运行在最终阶段，比

如10个朋友分开完两份并统计好两种的数量，该计算任务在自己分区的cluster上计算，把结果返回给deriver(你自己)，你再将最终结果10kg豆子汇总成最终结果。复杂的任务可以有多个shuffle 的阶段

- **任务调度**：上图步骤3，任务集合被发生到调度程序后，构建任务到executor的映射，将任务分配到具体的内核，并在任务完成后继续分配直到任务集合完成。当任务完成或者失败时，executor都会向driver更新消息。具体向executor分配的顺序为：首先分配进程本地任务(process local), 然后节点本地(node local), 然后机架本地(rack local), 最后分配非本地任务或者推测任务(speculative task)
- **任务执行**：上图步骤7，首先executor会确保任务相关的依赖文件和jar包都是最新的，然后由于任务代码经过序列化后发送到集群上的，先反序列化任务代码和函数，最后执行代码，由于任务运行在executor相同的JVM中，任务启动没有进程开销。

执行器和集群管理，executor具体是如何工作的

- Spark 任务要依赖executor来运行任务，而管理executor的为集群管理器cluster manager.Spark 提供了各种不同特征的集群管理器。
- **本地模式** local: executor 和driver在同一个JVM中，用于测试和小规模数据。
- **独立模式** standalone: 实现了简单的分布式系统，运行一个master多个worker, Spark 启动时 master 控制worker生成多一个或多个executor.
- **YARN**: YARN是Hadoop使用的资源管理器，每个运行的Spark应用对应一个YARN的实例，每个executor在自己的YARN容器中运行。YARN相对于独立模式的优点是它考虑了集群上的其他应用，同一协调它们之间的资源和调度。YARN分为客户端模式(client)和集群模式(cluster)
- **YARN client**: driver程序在客户端运行，即独立与集群的另一台机器。1.drier构建新的spark contex实例时就启动了与YARN之间的关联，2，3.提交YARN应用后启动集群管理器上的容器，excutorLauncher的作用是向管理器请求资源启动backend进程，”真正的“executor的JVM. 启动executor的数量在spark-shell 中设置，还要设置每个用到的内核和内存数量。
- ```
  %spark-shell --master yarn-client \
      --num-executors 4 \
      --executor-cores 1 \
      --executor-memory 2g
  ```
-
  ```

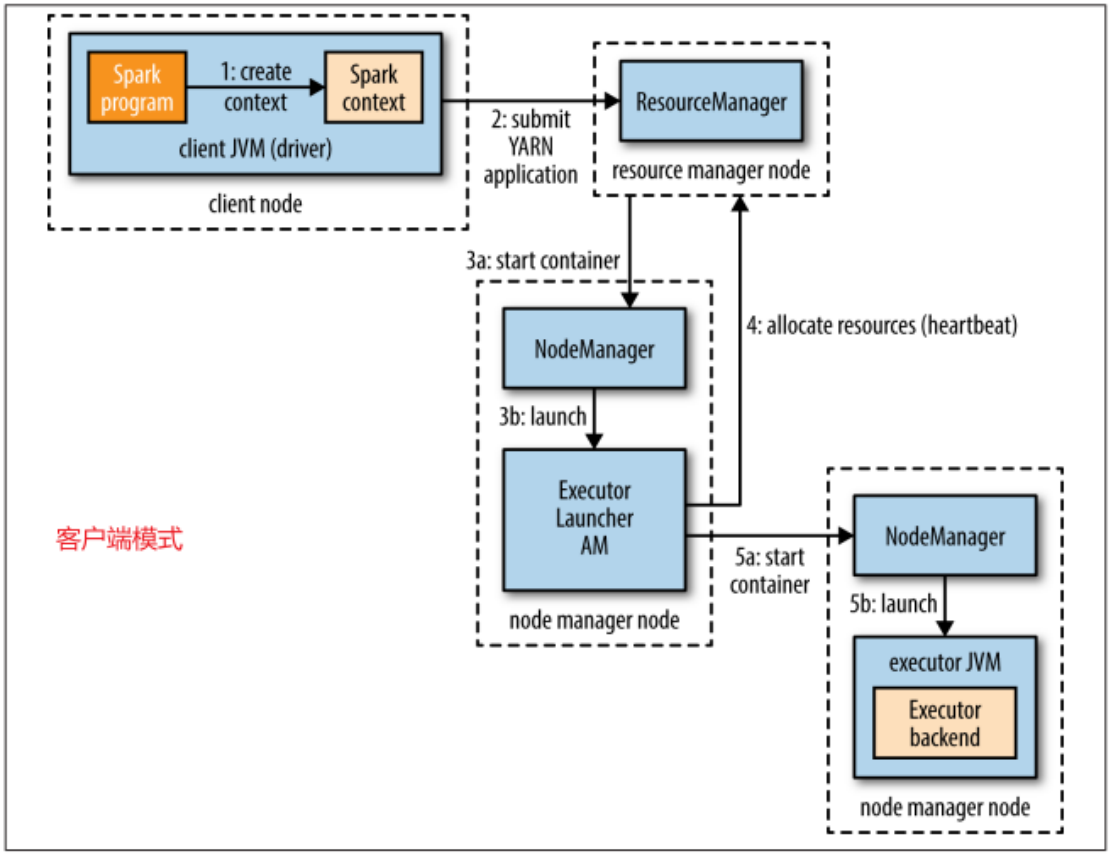

Figure 19-3. How Spark executors are started in YARN client mode

- **YARN Cluster**: driver程序在集群上运行. 客户端会启动YARN应用但是不会运行任何代码，注意图中的spark program是在集群中的容器中运行的。

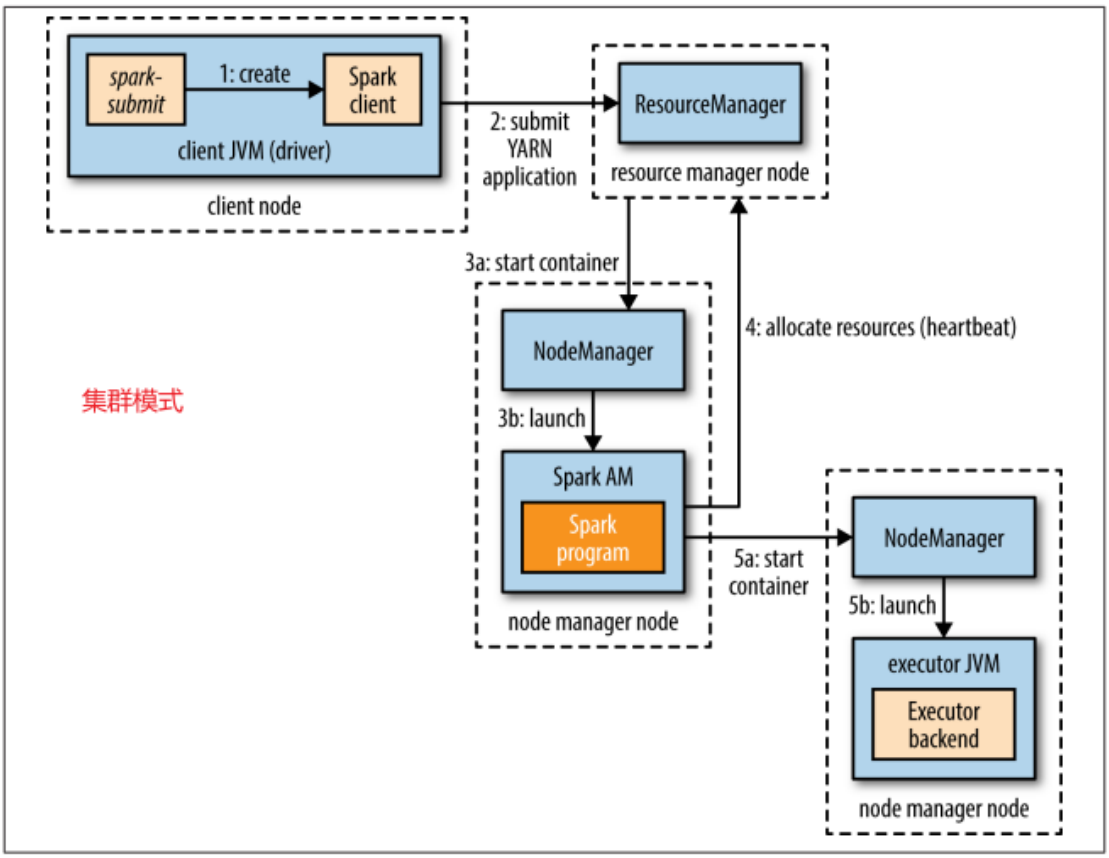

Figure 19-4. How Spark executors are started in YARN cluster mode

- 总结：不同部署模式对比：

Table 1-1. Cheat sheet for Spark deployment modes

Mode	Spark driver	Spark executor	Cluster manager
Local	Runs on a single JVM, like a laptop or single node	Runs on the same JVM as the driver	Runs on the same host
Standalone	Can run on any node in the cluster	Each node in the cluster will launch its own executor JVM	Can be allocated arbitrarily to any host in the cluster
YARN (client)	Runs on a client, not part of the cluster	YARN's NodeManager's container	YARN's Resource Manager works with YARN's Application Master to allocate the containers on NodeManagers for executors
YARN (cluster)	Runs with the YARN Application Master	Same as YARN client mode	Same as YARN client mode
Kubernetes	Runs in a Kubernetes pod	Each worker runs within its own pod	Kubernetes Master

4、rdd常用函数

转换 transformation 类型

map(func): 接收的函数作为参数， 用func对rdd内的每一个元素执行转换操作，返回新的rdd

```
//return split string
val data = Seq("Project Gutenberg's",
    "Alice's Adventures in Wonderland",
    "Project Gutenberg's",
    "Adventures in Wonderland",
    "Project Gutenberg's")
val df = data.toDF('data')

val mapDF = df.map(fun => {
    fun.getString(0).split(" ")})
mapDF.show()

//Output
+-----------------------------------+
|value                              |
+-----------------------------------+
|[Project, Gutenberg's]             |
|[Alice's, Adventures, in, Wonderland]|
|[Project, Gutenberg's]             |
|[Adventures, in, Wonderland]       |
|[Project, Gutenberg's]             |
+-----------------------------------+
```

flatMap(func), 和map类似，但是返回的df只有一列

filter(func), 将rdd每一个元素作为参数输入func中，func 返回为真的形成新的rdd.

groupByKey(), 对(key, value)对的数据进行操作，将key相同的合并为一组并对value进行比如累加、按长度等操作. 如果group的目的是聚合(sum /avg)用reduceByKey、aggregateByKey()会快很多.

reduceByKey(func): 同样是对(K,V)pair进行操作，返回(K,V), V的值对应一个key, 这个V是通过传进来的func函数对key进行reduce操作而来的。reduce函数的输入输出形式必须是(V, V) => V

```
#groupByKey例子，累加计算相同k的个数或者组合相同key
>rdd = sc.parallelize([("a", 1), ("b", 1), ("a", 1)])
>sorted(rdd.groupByKey().mapValues(len).collect())
[('a', 2), ('b', 1)]
>sorted(rdd.groupByKey().mapValues(list).collect())
[('a', [1, 1]), ('b', [1])]

#group by 例子
>rdd = sc.parallelize([1, 1, 2, 3, 5, 8])
>result = rdd.groupBy(lambda x: x % 2).collect()
>sorted([(x, sorted(y)) for (x, y) in result])
[(0, [2, 8]), (1, [1, 1, 3, 5])]

#reduce by key, reduce函数是加法函数
>from operator import add
>rdd = sc.parallelize([("a", 1), ("b", 1), ("a", 1)])
>sorted(rdd.reduceByKey(add).collect())
[('a', 2), ('b', 1)]

#filter
>rdd = sc.parallelize([1, 2, 3, 4, 5])
>rdd.filter(lambda x: x % 2 == 0).collect()
[2, 4]
```

名字	解释
Transformations	
map(func)	map操作，对rdd中每一个元素作为参数传入func中计算，返回新的rdd
groupBy(func)	返回经过聚合操作的rdd, 具体操作定义在func里
agg()	pyspark.pandas.Series.agg(), 对series上的数据进行聚合操作(min max, sum ...)
filter(func)	返回func为真的值
groupByKey([*numPartitions*])	When called on a dataset of (K, V) pairs, returns a dataset of (K, Iterable) pairs.
reduceByKey(func, [nums)	
Action	执行操作或计算并将结果返回
reduce(func)	根据func聚合计算rdd里每一个元素，即输入两个参数，返回一个为reduce操作
collect()	收集集群节点的所有rdd到master， 比如collect().foreach.(println)打印
take(n)	收集所有节点有爆内存的风险，take(10).foreach(print)查看前十个
toPandas()	转换成pd dataframe方便查看和操作
count()	计算
countDistinct()	每个值只计算一次
foreach(func)	对rdd里每一个函数运行一次func函数

参考资料

主要笔记来自阅读以下两本书：

1. Hadoop: The definitive guide
2. Learning Spark 2nd

有用的网页：

1. https://phoenixnap.com/kb/rdd-vs-dataframe-vs-dataset
2. [Apache Spark Tutorial with Examples - Spark by {Examples} (sparkbyexamples.com)](https://sparkbyexamples.com/
3. 项目来自于udecity的课程大项目
4. https://spark.apache.org/docs/latest/rdd-programming-guide.html